

# Relatorio Inicial de Analise

*Desafio: Antecipacao de Alertas Criticos em Frotas de Mineracao*

Este documento consolida a etapa de **Entendimento do Negocio** e **Inspecao Inicial dos Dados** (Conteudos Minimos 1.1, 1.2 e 2.1 do Estudo Guiado). Apresenta o mapeamento das fontes disponiveis, as principais caracteristicas dos dados de telemetria e apontamentos, e define a pergunta analitica que orientara a modelagem.

**Autor:** Marcelo Ayala

**Data:** 28 de abril de 2026

**Edicao:** Programa Desenvolver 2026

# 1. Entendimento do Negocio

## 1.1 Contextualizacao da Operacao de Mina

A operacao de mineracao analisada corresponde a regio de **Itabira**, envolvendo **32 equipamentos** distribuidos entre Caminhoes (793-D em varias series) e Escavadeiras (carregadeiras L-XXXX). Cada equipamento executa ciclos operacionais (apontamentos) que sao acompanhados por uma esteira continua de eventos de telemetria provenientes dos sensores embarcados (motor, transmissao, freios, hidraulico, pneus, etc.).

**Alertas Don't Go:** sao alertas criticos que sinalizam que o equipamento **nao deve operar**. Tem impacto direto em (i) seguranca do operador, (ii) disponibilidade da frota e (iii) producao da mina. A ocorrencia de um Don't Go normalmente exige parada imediata e intervencao da manutencao.

**Catalogo de regras:** o arquivo *Alarmes - SUL\_SUDESTE.xlsx* lista as combinacoes de TIPO + EVENTO + SITUACAO + NIVEL que constituem um Don't Go. Exemplos de eventos com criticidade **Muito Alto**:

- Low Engine Oil Pressure - em qualquer situacao
- High Engine Coolant Temperature - mediante alarme nivel 3
- Low Transmission Oil Level - mediante alarme nivel 3
- Hydraulic Reservoir Oil Temperature Critically High
- HPD Gearbox Oil Pressure Critically Low

## 1.2 Definicao do Problema Analitico

**Pergunta analitica escolhida:** Dado o historico recente de eventos de telemetria de um equipamento, qual a probabilidade dele gerar um alerta **Don't Go** nas proximas 4 horas?

**Justificativa da janela de 4 horas:**

- Tempo suficiente para a manutencao mobilizar peca/equipe;
- Curto o bastante para que o estado atual do equipamento ainda seja preditivo;
- Compativel com o ciclo medio de turno operacional (6h em Itabira).

**Metrica de sucesso de negocio:**

- Recall sobre os Don't Go - perder um alerta significa parada nao planejada;
- Precision aceitavel - falsos positivos geram intervencoes desnecessarias;
- Tempo medio de antecipacao do alerta - quanto antes, mais valor.

**Cenario de aplicacao:** integracao com o sistema de monitoramento do dispatcher, gerando uma *fila priorizada de inspecao* a cada turno.

## 2. Mapeamento das Fontes de Dados

Foram identificadas tres fontes de dados na pasta *Downloads/datasets/datasets/*:

### 2.1 Apontamentos

Arquivo: `desenvolver_apontamentos.parquet` (5,9 MB).

Cada linha representa um **ciclo de atividade** de um equipamento.

| Atributo            | Valor                               |
|---------------------|-------------------------------------|
| Numero de registros | 377.907                             |
| Numero de colunas   | 7                                   |
| Periodo coberto     | 01/01/2025 a 30/06/2025 (6 meses)   |
| Valores nulos       | 0 em todas as colunas               |
| TAGs distintas      | 32                                  |
| Frotas distintas    | 5 (793-D 2S/3S/4S/5S e familias L-) |
| Tipos               | Caminhao, Escavadeira               |

#### Colunas:

`Id, Inicio, Fim, Tag, Frota, Tipo, Classe`

**Observacao:** o Dicionario de Dados oficial menciona *Nome\_Operador\_Anon* e *Matricula\_Operador\_Hash*, mas estas colunas **nao estao presentes em Apontamentos**. O operador aparece apenas na tabela de Telemetria. Esse desvio entre dicionario e dado real foi registrado e deve constar no Controle de Alteracoes.

### 2.2 Telemetria

Sao 6 arquivos parquet mensais (jan a jun/2025) totalizando ~210 MB em disco e **~32 milhoes de eventos**. Cada linha e um evento de sensor ja classificado quanto a criticidade.

| Arquivo                            | Tamanho |
|------------------------------------|---------|
| <code>telemetry_jan.parquet</code> | 33 MB   |
| <code>telemetry_feb.parquet</code> | 32 MB   |
| <code>telemetry_mar.parquet</code> | 32 MB   |
| <code>telemetry_abr.parquet</code> | 36 MB   |
| <code>telemetry_may.parquet</code> | 34 MB   |
| <code>telemetry_jun.parquet</code> | 43 MB   |

**Volume verificado em janeiro/2025:** 5.400.002 registros, ocupando ~4 GB de RAM apos carga em pandas.

#### 18 colunas detectadas:

`Id_Eventos_Telemetria, Data_Evento, Inicio_Turno, Fim_Turno, Dia, Localidade, TAG, Tag_Frota, Tipo, Nome_Operador_Anon, Matricula_Operador_Hash, Id_Alarme, Alarme, Id_Criticidade, Criticidade, Valor, Classe, Is_Dont_Go`

**Achado-chave:** a coluna **Is\_Dont\_Go** (0/1) ja codifica o rotulo do problema. Nao sera necessario aplicar manualmente as regras do arquivo *Alarmes - SUL\_SUDESTE.xlsx* sobre os eventos para rotular o alvo - o

ground truth ja esta disponivel.

## 2.3 Exemplo Don't Go

Arquivo: desenvolver\_dontgo.xlsx (21 KB).

Contem 147 eventos consecutivos do caminhao **CA65924** (frota 793-D 4S, operador OP\_067) ilustrando uma sequencia de telemetria que culminou em alerta Don't Go. E um caso didatico para entender o padrao '*calmaria -> acumulo de alarmes -> disparo*'.

### 3. Inspecao Inicial dos Dados (CM 2.1)

#### 3.1 Distribuicao de Is\_Dont\_Go (janeiro/2025)

| Classe         | Quantidade | Proporcao |
|----------------|------------|-----------|
| Is_Dont_Go = 0 | 5.397.421  | 99,9522%  |
| Is_Dont_Go = 1 | 2.581      | 0,0478%   |
| TOTAL          | 5.400.002  | 100%      |

**Desbalanceamento extremo:** aproximadamente 1 evento Don't Go a cada 2.092 eventos. Esse desequilibrio determina a estrategia de modelagem - acuracia sera enganosa, precisaremos de Recall, Precision, F1, AUC-PR e tecnicas como class\_weight, SMOTE ou under/oversampling.

#### 3.2 Cruzamento Criticidade x Is\_Dont\_Go

| Criticidade   | Don't Go = 0 | Don't Go = 1 |
|---------------|--------------|--------------|
| Informacional | 5.319.047    | 0            |
| Critico       | 24.732       | 2.077        |
| Nao Critico   | 53.631       | 504          |
| TOTAL         | 5.397.410    | 2.581        |

##### Observacoes:

- Eventos **Informacionais nunca sao Don't Go** - podem ser filtrados para reduzir o volume de processamento sem perda de positivos;
- **80% dos Don't Go** tem criticidade 'Critico' - o alarme em si ja carrega forte sinal;
- Os 504 Don't Go com criticidade 'Nao Critico' sao um caso interessante: alertas que **so sao criticos por acumulo** (regra QTD > 1 nas regras de negocio);
- A coluna Criticidade tem encoding inconsistente ('Critico', 'N o Cr tico' aparecem com caracteres corrompidos) - precisara ser normalizada na limpeza.

#### 3.3 Top 5 Alarmes que Geram Don't Go (janeiro)

| Alarme                                 | Qtd   |
|----------------------------------------|-------|
| Engine Coolant Level - Active          | 1.505 |
| Aftercooler Level - Active             | 249   |
| Transmission Oil Level - Active        | 205   |
| Left Rear Brake Temperature - Active   | 160   |
| Right Front Brake Temperature - Active | 116   |

Esses 5 alarmes concentram **~88% dos Don't Go** de janeiro. Bate exatamente com as regras de NIVEL 'Muito Alto' do catalogo de regras de negocio - confirmacao de que a coluna Is\_Dont\_Go foi construida corretamente a partir do *Alarmes - SUL\_SUDESTE.xlsx*.

#### 3.4 Universo de Equipamentos

| Dimensao | Valor |
|----------|-------|
|----------|-------|

|                            |                           |
|----------------------------|---------------------------|
| TAGs unicas (equipamentos) | 32                        |
| Frotas distintas           | 5                         |
| Tipos                      | 2 (Caminhao, Escavadeira) |
| Localidades                | 1 (Itabira)               |

## 4. Implicacoes para a Modelagem

### 4.1 Tipo de Problema

**Classificacao binaria altamente desbalanceada** (taxa positiva ~ 0,05%). Alvo: *vai ocorrer Is\_Dont\_Go = 1 nas proximas 4 horas para um equipamento dado o seu historico recente?*

### 4.2 Desafios Tecnicos Identificados

- **Volume:** ~32 milhoes de eventos = ~24 GB em RAM se carregado naive. Necessario uso de Polars/Dask, leitura por colunas, ou agregacao previa por janela de tempo;
- **Desbalanceamento:** exige class\_weight, oversampling (SMOTE) ou undersampling do negativo, e metricas apropriadas (AUC-PR, F1, Recall);
- **Validacao temporal:** dividir treino/validacao/teste por data (ex: jan-abr / mai / jun). NUNCA shuffle aleatorio - causa data leakage em serie temporal;
- **Encoding inconsistente:** coluna Criticidade tem caracteres corrompidos a normalizar;
- **Junção temporal:** apontamentos e telemetria precisam ser alinhados pela TAG e por janelas de tempo, nao por join exato.

### 4.3 Estrategia de Features Proposta

- **Agregacao por janela movel** de 1h, 4h e 24h por equipamento: contagem total de eventos, contagem por criticidade, contagem dos top alarmes precursores;
- **Features de recencia:** tempo desde o ultimo Don't Go, tempo desde o ultimo evento Critico, taxa de eventos por hora;
- **Features temporais:** hora do dia, turno, dia da semana, mes;
- **Features do equipamento:** TAG, Frota, Tipo (encoding apropriado);
- **Features do operador:** taxa historica de Don't Go por operador;
- **Features de atividade** (apontamentos): % do tempo Operando vs Parado nas ultimas N horas, duracao media de ciclo.

### 4.4 Modelos Candidatos

- **Baseline:** regra heuristica - prever Don't Go se houve evento Critico do mesmo TAG nas ultimas 4h;
- **Modelo principal 1: LightGBM** com class\_weight - rapido, robusto, lida bem com tabular desbalanceado;
- **Modelo principal 2: Isolation Forest** sobre features agregadas - abordagem nao supervisionada de deteccao de anomalia, comparada com Is\_Dont\_Go como ground truth.

## 5. Proximos Passos

- **EDA completa** (CM 2.2 e 2.3): serie temporal de Don't Go, padroes por hora/turno/dia, distribuicao por TAG e frota, heatmaps de correlacao;
- **Pipeline de carga eficiente** dos 6 meses de telemetria com Polars ou agregacao incremental;
- **Construcao da matriz de features** com janelas moveis e alinhamento temporal com apontamentos;
- **Definicao formal do split temporal** (datas de corte para treino/validacao/teste);
- **Implementacao do baseline** e do primeiro modelo LightGBM para estabelecer referencia de performance.

**Status atual:** Conteudos Minimos 1.1, 1.2 e 2.1 cobertos. Pronto para iniciar EDA aprofundada (CM 2.2/2.3) ou construcao da matriz de features (CM 3.1/3.2).